

CycleGAN 實作

統計碩二

107354012

陳冠廷

一、研究動機

Generative Adversarial Network (GAN)，中文譯作生成對抗網路，是一項被譽為近10年來最有趣的深度學習技術，它透過兩個模型進行「對抗式」的學習，來達成模型的目標，舉例來說，一個模型專門製作假鈔，而另一個模型則是辨識真假鈔，而這兩個模型會彼此較勁，透過不斷的優化模型，最後則會使模型能夠訓練出能製作出以假亂真的假鈔的能力。

而CycleGAN則是一種基於GAN的技術，能夠將照片在兩種風格間互相轉換，且不需要成對的輸入以及輸出圖片，這使得在資料的蒐集上多了很多自由，可以在不為目標圖片標註專屬的標籤下訓練，這是在CycleGAN技術發布以前，較難達成的。利用CycleGAN的這項優勢，可以透過互相的轉換彌補資料的不足，例如過去在訓練自駕車時，便透過了這項技術將白天轉為夜晚來彌補夜晚資料的不足，同時也能透過將夜晚的圖片轉為白天，繼續為模型提供更多的資料。

此次期末，我便打算藉此機會來進行CycleGAN的實作，希望在實作的過程中，能夠更了解模型背後的原理，也讓自己多學習與一般深度學習架構較不同的技術。而此次期末，我將使用Pytorch以及夏天冬天的資料集來實作，並觀測在不同超參數下，模型訓練出的結果。

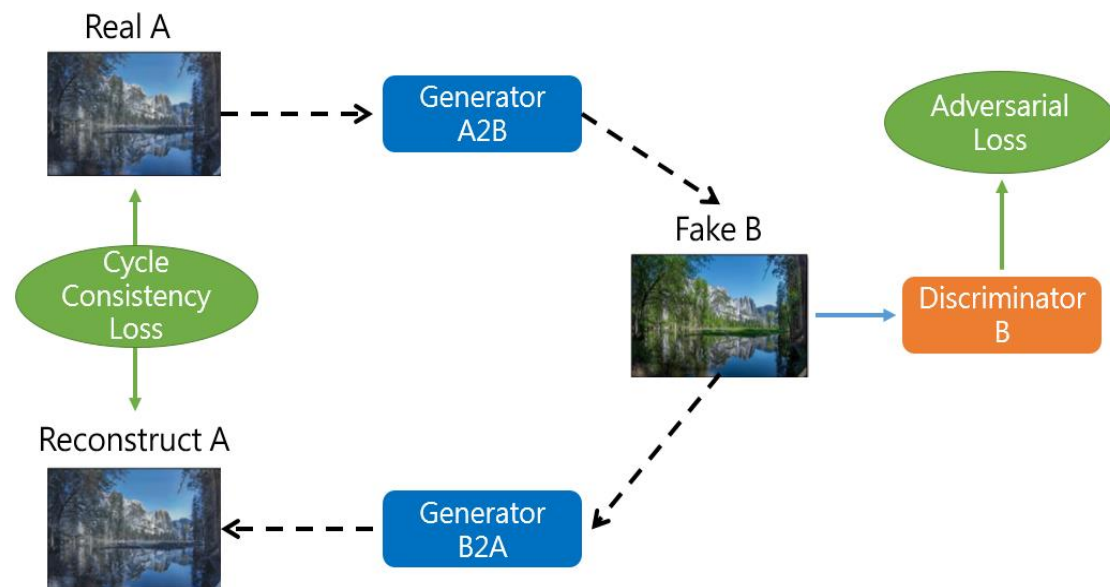
二、CycleGAN 介紹

甲、模型架構

CycleGAN 模型由兩個 Generator 及兩個 Discriminator 組成，將兩種風格記為 A 及 B，Generator 可以分為 Generator A2B 以及 Generator B2A，Generator A2B 將 A 風格的圖片轉換為 B 風格，Generator B2A 則是將 B 風格的圖片轉換為 A 風格。同樣地，Discriminator 也可以分為 Discriminator A 以及 Discriminator B，Discriminator A 預測在 A 風格的圖片中，某圖片是否為真，而 Discriminator B 預測在 B 風格的圖片中，某圖片是否為真。

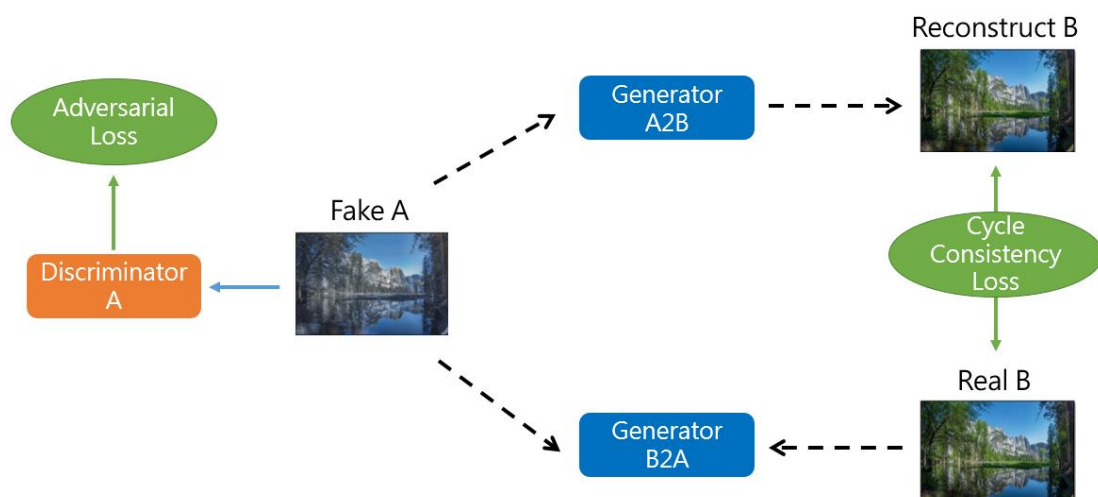
下圖(圖一)代表 A 風格圖片在 CycleGAN 模型中的運作流程，首先，A 風

格圖片會透過 Generator A2B 轉換為 B 風格圖片，並透過 Discriminator B 來預測其真偽，同時 B 風格圖片會再經由 Generator B2A 轉換為 A 風格圖片。



圖一、A 風格的圖片在 CycleGAN 模型中的運作


同樣地，下圖(圖二)代表 B 風格圖片在 CycleGAN 模型中的運作流程，首先，B 風格圖片會透過 Generator B2A 轉換為 A 風格圖片，並透過 Discriminator A 來預測其真偽，同時 A 風格圖片會再經由 Generator A2B 轉換為 B 風格圖片。



圖二、B 風格的圖片在 CycleGAN 模型中的運作

此次實作我使用的模型架構，均與原論文中[1] Zhu, J 等人所使用的相同，在 Generator 的部分，一共使用了 9 個殘差塊，而 Discriminator 的部分，作者使用的架構與常見的 GAN 不同，在此研究中採用[2]裡，Isola, P 等人所使用

的 PatchGAN。常見 GAN 的 Discriminator，通常都只有輸出一個 0 到 1 之間的值，而這樣的作法容易損失掉太多圖片的訊息，因此在這裡作者所使用的 PatchGAN 概念，即為輸出一個矩陣，矩陣的每一個元素都在 0 到 1 之間，會使用這項技術的用意在於，透過 Discriminator 的運作，輸出的矩陣相當於對原圖中的一部份圖片做判斷，判斷各小區塊的圖片是否為真，這樣便能提高模型的辨識能力。



圖三、PatchGAN 運作示意圖

乙、 損失函數介紹

在前一節中，圖片經過任一 Generator 轉換後，都會透過 Discriminator 辨識其真偽，而轉換後的圖片會再經由另一個 Generator，還原為原始風格圖片。在 CycleGAN 中，透過 Discriminator 預測結果所計算出的損失函數稱為 Adversarial Loss，而為了確保圖片經由 Generator 轉換並還原後，仍能與原始輸入圖片相像，因此作者提出了 Cycle Consistency Loss。

若我們將 Generator A2B 記作 G_{A2B} ，Generator B2A 記作 G_{B2A} ，Discriminator A 記作 D_A ，Discriminator B 記作 D_B ，則我們可以寫出 Adversarial Loss 在各模型的式子如下：

- Adversarial Loss for G_{A2B} :

$$L_{Adv}(G_{A2B}) = E_{x \sim P(B)} [D_A(G_{B2A}(x)) - 1]^2$$

- Adversarial Loss for G_{B2A} :

$$L_{Adv}(G_{B2A}) = E_{x \sim P(B)} [D_A(G_{B2A}(x)) - 1]^2$$

- Adversarial Loss for D_A :

$$L_{Adv}(D_A) = E_{x \sim P(B)} [D_A(G_{B2A}(x)) - 0]^2 + E_{y \sim P(A)} [D_A(y) - 1]^2$$

- Adversarial Loss for D_B :

$$L_{Adv}(D_B) = E_{x \sim P(A)} [D_B(G_{A2B}(x)) - 0]^2 + E_{y \sim P(B)} [D_B(y) - 1]^2$$

而 Cycle Consistency Loss 則是僅針對 Generator 提出的損失函數，計算式如下：

$$L_{cyc}(G_{A2B}, G_{B2A}) = E_{x \sim P(A)} \|G_{B2A} \circ G_{A2B}(x) - x\|_1 \\ + E_{y \sim P(B)} \|G_{B2A} \circ G_{A2B}(y) - y\|_1$$

在有這兩種損失函數後，便能透過這兩種損失函數結合出各模型最終所需使用的損失函數，作者將各模型的損失函數提出如下：

- For G_{A2B} and G_{B2A} :

$$L_{Adv}(G_{A2B}) + L_{Adv}(G_{B2A}) + \lambda \cdot L_{cyc}(G_{A2B}, G_{B2A})$$

- For D_A :

$$L_{Adv}(D_A) / d_ratio$$

- For D_B :

$$L_{Adv}(D_B) / d_ratio$$

其中 λ 是為了確保讓圖片經過 Generator 轉換後，能有相當大程度的還原，因此提高模型的 Cycle Consistency Loss，而 d_ratio 則是為了讓 Discriminator 的學習速度不要太快，導致無法讓 Generator 有效的進步。


三、實作結果

在這次研究中，我將 λ 及 d_ratio 調為(1) $\lambda = 10, d_ratio=2$ (2) $\lambda = 10, d_ratio=1$ (3) $\lambda = 5, d_ratio=1$ 一共三種組合來訓練模型，並觀察模型訓練後結果的差異，由於測試集照片較多，以下僅挑出較有鑑別度的照片來進行評論。

1. 以夏天的政大校門口進行轉換：



圖三、原圖




圖四、各超參數下 CycleGAN 轉換成冬天的照片

從圖四可以看出 $\lambda = 5$, $d_ratio=1$ 時，樹葉呈現的較有冬天的感覺，而另外兩張的圖片，綠葉依然佔了較大的比例，與冬天應呈現的殘葉景象較不相同。

2. 以冬天的政大校門口進行轉換：



圖五、原圖

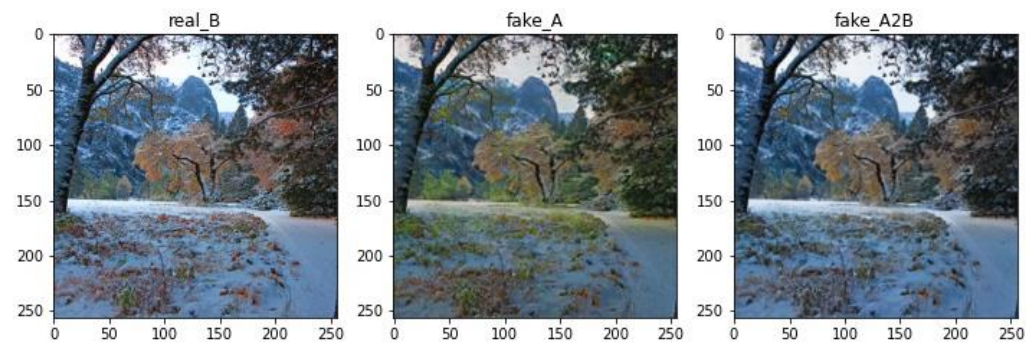


圖六、各超參數下 CycleGAN 轉換成夏天的照片

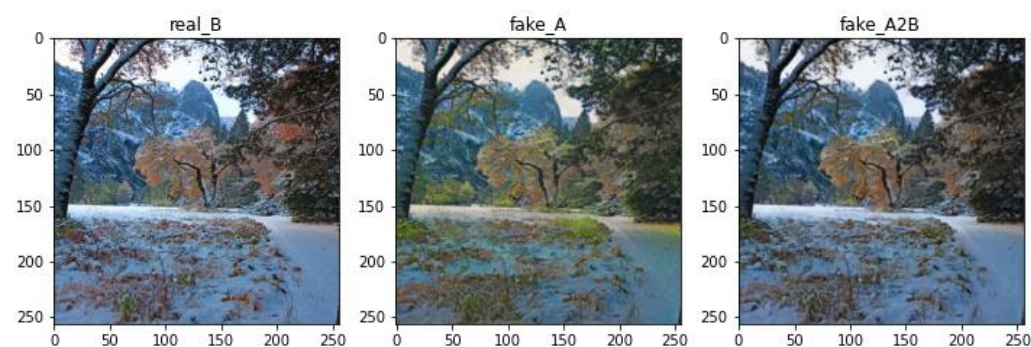
從圖六中可以發現，各參數下的模型，將冬天轉換為夏天的能力差不多，經過轉換後的圖片，樹葉明顯變鮮綠許多，與夏天呈現的景象較相像。

3. 以 testing data 中的冬天圖片進行轉換:


(1) $\lambda = 10$, $d_ratio=2$



(2) $\lambda = 10$, $d_ratio=1$




(3) $\lambda = 5$, $d_ratio=1$




當圖片過多冬天意象像是雪時，會發現在各超參數下的 CycleGAN 沒辦法將冬天完美轉為夏天，原因應是我們在訓練模型時，模型的損失函數會較在意還原照片的能力也就是 Cycle Consistency Loss，因此訓練後的 Generator 較不會對圖片作出較大的修改，導致在這類雪較多的圖片時，模型僅會將部分特徵轉為夏天的意象。

4. 以 testing data 中像冬天的夏天圖片進行轉換:

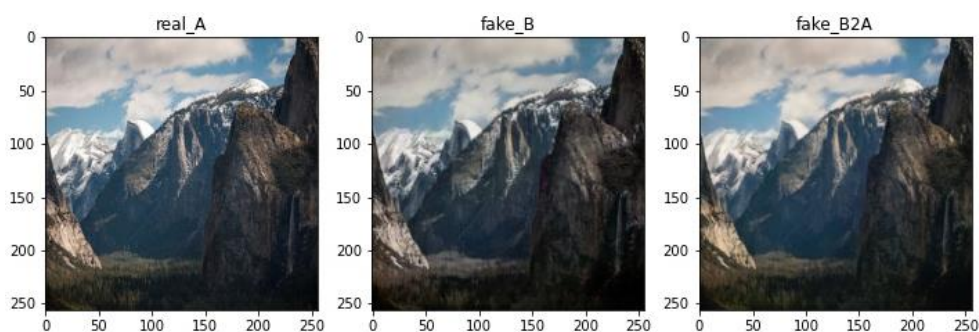
(1) $\lambda = 10$, $d_ratio=2$



(2) $\lambda = 10, d_ratio=1$

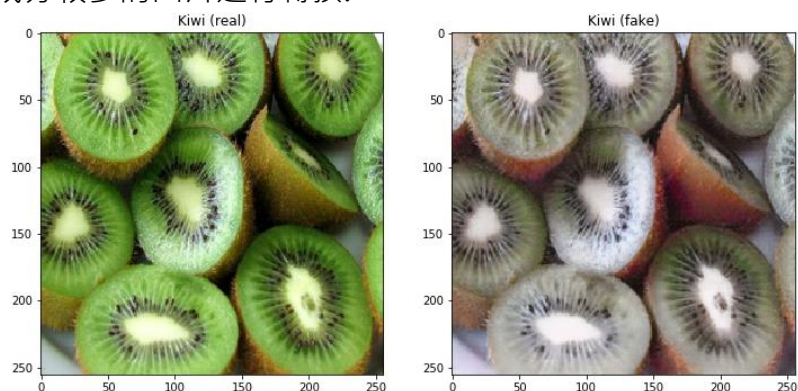


(3) $\lambda = 5, d_ratio=1$



當夏天的圖片太像冬天的意象時，會發現在各超參數下的 CycleGAN 將圖片轉換為冬天時，並不會有大幅度的改變，這樣的結果對於模型算是蠻理想的，因為有些地區像是高山或者極區，當地的景象並不會因夏冬天而有明顯的變化。

5. 以綠色成分較多的圖片進行轉換:



從夏天冬天轉換間的變化中發現，大部分圖片看似雖能將夏天轉為冬天，或者將冬天轉為夏天，然而，通常這些的轉變都是將較鮮綠的顏色(代表夏天)轉換為較冷灰的顏色(代表冬天)，因此我將奇異果這張鮮綠的圖片放入模型中，觀察預測結果，模型的確將鮮綠的果肉部分，轉換為較冷灰的顏色，代表模型訓練出的季節轉換能力，主要應是進行這兩種顏色的變換。

四、 結論

從超參數的調整中，可以發現在夏天冬天資料集中，當 $\lambda = 5$, $d_ratio=1$ 時，CycleGAN 的轉換轉換能力較符合期待，原因應是 λ 較另外兩組來的小，模型能做出較大的轉換。此外，從奇異果的照片轉換中，可以看出訓練出的季節轉換能力，主要應是進行讓讓整體的顏色，在鮮綠以及冷灰中轉換，若未來要對於此模型進行改進，應可以從讓模型對於適當的目標才進行轉換這部分開始著手，如此一來可以更增進模型轉換後的品質。

五、 參考文獻

- [1] Zhu, J. Y., Park, T., Isola, P., & Efros, A. A. (2017). Unpaired image-to-image translation using cycle-consistent adversarial networks. In *Proceedings of the IEEE international conference on computer vision* (pp. 2223-2232).
- [2] Isola, P., Zhu, J. Y., Zhou, T., & Efros, A. A. (2017). Image-to-image translation with conditional adversarial networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 1125-1134).